

数学基础与线性回归

刘满华

2025年3月29日

饮水思源 · 爱国荣校

目 录

1

机器学习简介

2

数学基础

3

寻优算法

4

线性回归



1. 机器学习简介 — 什么是机器学习?



- **机器学习 (Machine Learning)** 是计算机在**数据**中学习**规律**，并根据所得规律对**未来数据**进行**预测**，是人工智能的一个重要分支。



- **Arthur Samuel 的定义**
 - 在进行特定编程的情况下，给予计算机学习能力的领域
- **Tom Mitchell 的定义**
 - 如果计算机程序在**任务T**上的性能（由**P衡量**）随着**经验E**而提高，则称计算机程序从经验E中学习某类任务T。




1. 机器学习简介 — 机器学习的分类



按学习方式分：


▪ 监督学习 (Supervised Learning)

- 我们教计算机如何去完成任务 (有教师)
- 回归、分类




▪ 无监督学习 (Unsupervised Learning)


- 计算机自己进行学习 (无教师)
- 聚类、降维



Supervised learning



Unsupervised learning




1. 机器学习简介 — 回归与分类



按输出任务分：

- 预测气温：回归（Regression），输出变量是连续的
- 预测天气：分类（Classification），输出变量是离散的



目 录

1

机器学习简介

2

数学基础

3

寻优算法

4

线性回归

2. 数学基础 — 导数的定义




■ 例1：瞬时速度问题

- 一质点在 x 轴上作变速直线运动，运动方程 $x = f(t)$ ，求 t_0 时刻的瞬时速度，瞬时速度是矢量，既有大小又有方向

- 平均速度： $\bar{v} = \frac{\Delta x}{\Delta t} = \frac{f(t) - f(t_0)}{t - t_0}$

- 当 $t \rightarrow t_0$ 时，取极限得瞬时速度 $v_{t=t_0} = \lim_{t \rightarrow t_0} \frac{f(t) - f(t_0)}{t - t_0}$



2. 数学基础 — 导数的定义




■ 例2：切线问题

- 如果割线MN绕点M旋转而趋向极限位置MT，直线MT就称为曲线C在点M处的切线
- 设点M(x_0, y_0)、点N(x, y)，则割线MN的斜率为：

$$\tan \varphi = \frac{y - y_0}{x - x_0} = \frac{f(x) - f(x_0)}{x - x_0}$$

- 当 $N \rightarrow M$ 即 $x \rightarrow x_0$ 时，切线MT的斜率为：

$$\tan \alpha = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0}$$



2. 数学基础 — 导数的定义



■ 导数的定义:

- 设函数 $y = f(x)$ 在点 x_0 的某个邻域内有定义, 当自变量 x 在 x_0 处有增量 Δx , $x_0 + \Delta x$ 也在该邻域时, 对应的函数取得增量:

$$\Delta y = f(x_0 + \Delta x) - f(x_0)$$

- 如果 Δy 与 Δx 之比, 当 $\Delta x \rightarrow 0$ 时, 极限存在, 则称函数 $f(x)$ 在 x_0 处可导, 并称这个极限为函数 $y = f(x)$ 在点 x_0 处的导数记为 $f'(x_0)$, 即:

$$f'(x_0) = \lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$




2. 数学基础 — 导数的几何意义



■ 导数的几何意义:

- $f'(x_0)$ 表示 $y = f(x)$ 上点 $M(x_0, y_0)$ 处的斜率



2. 数学基础 — 多元函数与偏导数



- **多元函数：**

- 有两个及以上自变量的函数统称为多元函数：

- 例： $f(x, y) = x^2 + 3xy + y^2$

- **偏导数：**

- 多元函数关于其中一个变量的导数而保持其他变量恒定：

- 例： $f'_x = 2x + 3y$ 以及 $f'_y = 3x + 2y$



2. 数学基础 — 常用函数的导数



■ 常用导数:

- $y = c$ (c 为常数) , 则 $y' = 0$
- $y = x^\alpha$, 则 $y' = \alpha x^{\alpha-1}$
- $y = \alpha^x$, 则 $y' = \alpha^x \ln \alpha$, 特例: $(e^x)' = e^x$
- $y = \log_a x$, 则 $y' = \frac{1}{x \ln a}$, 特例: $(\ln x)' = \frac{1}{x}$
- $y = \sin x$, 则 $y' = \cos x$
- $y = \cos x$, 则 $y' = -\sin x$
- $y = \tan x$, 则 $y' = \frac{1}{\cos^2 x} = \sec^2 x$



2. 数学基础 — 复合函数求导



▪ 复合函数求导的链式法则：

- $y = f(u)$ 和 $u = g(x)$, 其复合函数为 $y = f(g(x))$
- 对 $y = f(g(x))$ 求导, 有: $y'_x = y'_u \cdot u'_x$

▪ 例1: $y = (2x + 3)^2$

- 可被看作是 $y = u^2$ 和 $u = 2x + 3$ 的复合函数
- $y'_x = y'_u \cdot u'_x = (u^2)'_u \cdot (2x + 3)'_x = 2u \cdot 2 = 8x + 12$

▪ 例2: $y = e^{-0.05x+1}$

- 可被看作是 $y = e^u$ 和 $u = -0.05x + 1$ 的复合函数
- $y'_x = y'_u \cdot u'_x = (e^u)'_u \cdot (-0.05x + 1)'_x = e^u \cdot (-0.005) = -0.005e^{-0.05x+1}$



目 录

1

机器学习简介

2

数学基础


3

寻优算法


4

线性回归


3. 寻优算法 —— 什么是寻优?



一维寻优



二维寻优




寻优算法的任务，就是找到函数的最小值

例：计算最小成本、最短路径、最小损失.....


3. 寻优算法 —— 为什么要算法?



$$\min f(x) : x^2 - 6x + 10$$



$$\min f(x) : \frac{e^x}{1000} + \frac{x^2}{10} - 3x + 27$$



如何找到函数的最小值?




3. 寻优算法 —— 什么是梯度?



导数定义

$$\frac{dy}{dx} = f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x+\Delta x) - f(x)}{\Delta x}$$




梯度定义


$$\nabla f(x, y)$$

$$= \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$

$$= \frac{\partial f}{\partial x} \cdot i + \frac{\partial f}{\partial y} \cdot j$$




3. 寻优算法 —— 梯度下降法



想象在山顶放了一个球，一松手它就会顺着山坡最陡峭的地方滚落到谷底

$$f(x) = x^2$$



梯度下降法就是通过沿着**负梯度方向**不断迭代，找到梯度为0的位置，迭代公式 $x_{n+1} = x_n - f'(x_n)$



3. 寻优算法 —— 梯度下降法



$$\min f(x) : x^2$$

梯度下降算法步骤：



1. 给定起始点 x_0 计算导数 $f'(x_0)$

2. 迭代： $x_{n+1} = x_n - \alpha f'(x_n)$

α ：步长，控制移动的距离

$$x_1 = x_0 - \alpha f'(x_0) = 10 - 0.2 * 20 = 6$$

3. 重复步骤2，直至 $f'(x_n)$ 的绝对值足够小






3. 寻优算法 — 梯度下降法的性能分析

- 步长 α 影响:

随着迭代次数增加, 导致函数值有不同变化:

- α 太小: $\alpha=0.01$, 迭代缓慢, 100 次都无法到达谷底
- α 适中: $\alpha=0.2$, 10 次就差不多找到最小值
- α 较大: $\alpha=1$, 迭代来回震荡
- α 太大: $\alpha=1.1$, 反而会越过谷底, 不断上升



3. 寻优算法——梯度下降法的性能分析




▪ 优点：计算简单

• 步长 α 影响：随着迭代次数增加，导致函数值有不同变化

如何寻找合适的步长？

- 往上走（红线），自然是过大，需要调低
- 一开始下降特别急，然后就几乎没有变化（棕线），可能是较大，需要调低
- 几乎是线性变化（蓝线），可能是过小，需要调高



目 录

1

机器学习简介

2

数学基础

3

寻优算法

4




线性回归

4. 线性回归 — 采样与回归



线性回归：用一条线来进行回归预测，就是寻求一条直线尽可能拟合那些离散点。

非线性回归：用曲线来进行回归预测



采样点和理想点的回归曲线

4. 线性回归 — 以房价预测为例



▪ 房价预测：

- 现有数据集是若干房屋房价与房屋面积的对应关系。
- 现在想要买一栋110平米的房子，能否通过之前的经验预测我需要花多少钱？

面积/m ²	房价/万	面积/m ²	房价/万
121	253	73	130
75	135	66	120
89	165	129	258
132	270	90	185
73	143	90	182
127	275	89	165
73	130	128	278
131	264.5	69	107




4. 线性回归 — 以房价预测为例



▪ 房价预测：

- 我们以房屋面积为横坐标，房屋价格为纵坐标，可以得到一张散点图。
- 观察散点图，可以分析出房屋价格与房屋面积的大致关系。




4. 线性回归 — 以房价预测为例



▪ 房价预测：

- 画一条直线，使得直线尽量地靠近图像中每一个房屋所对应的点。
- 这条直线可以帮助我们预测110平方米的房价。



4. 线性回归 — 求解线性回归问题



■ 求解线性回归的流程

- 建立合理的表达式 $f(x)$:

- 一元线性回归: $f(x) = wx + b$

- 多元线性回归: $f(x) = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$


$$f(x) = \sum_{j=1}^n w_j x_j + b = W^T X + b$$

- 构建合理的准则以确定表达式中参数的值:

- W: 权重 (weights)

- b: 偏置量 (bias)

- 对模型进行求解, 最终确定 $f(x)$ 。



线性回归



4. 线性回归 — 求解线性回归问题

- 如上例，房屋价格与面积关系如右表所示，
- 假设它们符合一元线性关系： $y = wx + b$
- 如果需要 w 对所有的样本都满足 $y_i = wx_i + b$
- 那么需要满足 16 个方程：

面积 /m ²	房价/ 万	面积 /m ²	房价/ 万
121	253	73	130
75	135	66	120
89	165	129	258
132	270	90	185
73	143	90	182
127	275	89	165
73	130	128	278
131	264.5	69	107

$$\begin{aligned} 253 &= w \times 121 + b \\ 135 &= w \times 75 + b \\ 165 &= w \times 89 + b \\ &\dots\dots \\ 107 &= w \times 69 + b \end{aligned}$$

方程组无解？

找到“尽量好”的解



偏差（误差平方和）最小

4. 线性回归 — 最小二乘



为使得误差最小，就需要对误差进行计算和衡量：

预测值为 $w x_i + b$ ，真实值为 y_i

可以利用误差的平方和，即 $\sum_{i=1}^m (y_i - (w^T x_i + b))^2$ 对拟合的效果进行衡量：

$$\min_{w,b} \sum_{i=1}^m (y_i - (w^T x_i + b))^2$$

其含义是寻找出一对 w 、 b 使得误差平方和最小。

因为是通过极小化误差平方和来求解回归问题，因此被称为“**最小二乘法**”（Least Squares）。



4. 线性回归 — 最小二乘



为求解最小二乘问题，需要将目标函数对参数 w, b 分别进行求导，得到**最优解**需要满足的条件，即

$$\frac{\partial \sum_{i=1}^m (y_i - (w^T x_i + b))^2}{\partial w} = 2 \sum_{i=1}^m (y_i - (w^T x_i + b)) x_i = 0$$

$$\frac{\partial \sum_{i=1}^m (y_i - (w^T x_i + b))^2}{\partial b} = 2 \sum_{i=1}^m (y_i - (w^T x_i + b)) = 0$$

由此得到了包含 M 个**未知数**的 M 个线性方程组，通过求解这个**线性方程组**（又被称为“**正则方程**” Normal Equation），就可以得到最小二乘问题的解。

设正则方程的解是 w^*, b^* ，则它们是最优解，即 $f(x) = w^{*T} x + b^*$ 所给出的回归直线，在所有直线中具有最小的误差平方和。



4. 线性回归 — 高维线性回归



- 以房价模型为例，影响房屋价格的因素还有很多
 - 房屋面积
 - 房间数量
 - 楼层数
 - 房屋年龄
- 我们可以使用如下所示的多元线性回归表达式来拟合
 - $f(x) = w_1x_1 + w_2x_2 + w_3x_3 + w_4x_4 + b$


写成向量表达式为： $f(x) = W^T X + b$



4. 线性回归 — 过拟合问题



- 虽然利用最小二乘得到的多项式在每一个采样点上都拟合得很好，但在非采样点上的准确度却不高。
- 在采样有**噪声**的情况下，过拟合带来的危害更大。
- 如果有更多的数据，就能减轻过拟合问题。




4. 线性回归 — 模型泛化性



➤ 正确拟合

- 泛化能力是指模型不仅能在训练数据上表现良好，还能在测试数据（未见过的数据）上表现优异。
- 模型适当复杂、能够准确捕捉数据的主要趋势和模式，能够泛化。
- 理想的模型应该能够在训练集上达到适度的拟合，同时能对测试集保持良好的预测效果。




4. 线性回归 — 模型泛化性



➤ 欠拟合

- 模型是线性的，数据呈现复杂的非线性模式，线性模型无法很好地拟合这些数据。
- 模型无法准确描述数据的趋势或模式。
- 在训练集和测试集上的误差都很高。




4. 线性回归 — 模型泛化性



➤ 过拟合

- 模型使用了非常高阶的多项式，拟合了每一个数据点，包括数据中的噪声，记住了细节，却忽略了数据的整体规律。
- 在训练集上表现非常好，但在测试集上表现不佳。
- 模型在新数据上的泛化能力较差





上海交通大学

SHANGHAI JIAO TONG UNIVERSITY



人工智能研究院

Artificial Intelligence Institute

谢谢!

饮水思源 爱国荣校