

# 分类算法 (Classification)

刘满华

2025年4月12日

—— 饮水思源 · 爱国荣校 ——

# 目 录

1

KNN分类

2

SVM分类

3

决策树分类




# 1. 分类算法 — 二分类与多分类



?

是不是猫?  $\rightarrow$  是 ( $y=1$ ) / 否 ( $y=-1$ )

**二分类**




是猫 ( $y=1$ )、狗 ( $y=2$ ) 还是兔子 ( $y=3$ ) ?

**多分类**

# 1. KNN分类算法



- K最近邻 (KNN, K Nearest Neighbor) 分类算法是一种监督学习算法，是机器学习分类方法中最简单的方法之一
- KNN中的K，指的是K最近邻，即选择与测试数据最接近的K个点来预测测试数据的类别




如何确定新样本点  属于哪一类 (  或者  ) ?



# 1. KNN分类算法



▪  $K = 3$  的情况:




$K=3$ :  2  1



# 1. KNN分类算法



▪  $K = 5$  的情况:



$K=3$ :  2  1



$K=5$ :  2  3





# 1. KNN分类算法

- 度量空间中点距离，有好几种度量方式，比如常见的曼哈顿距离，欧式距离等。
- KNN算法常用的是**欧式距离**，在二维平面中即两点之间的直线距离，计算公式如下：

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

- 若要拓展到多维空间，则公式变为：

$$d = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$



# 1. KNN分类算法



## ▪ KNN分类算法包括以下4个步骤：

1. 准备数据，对数据进行预处理





2. 计算测试样本点（也就是待分类点）到训练样本点的距离



3. 对每个距离进行排序，然后选择出距离最小的K个点



4. 对K个点所属的类别进行比较，根据少数服从多数的原则，将测试样本点归入在K个点中占比最高的一类



| Point Distance                                                                        |     |                                                                                       |              |
|---------------------------------------------------------------------------------------|-----|---------------------------------------------------------------------------------------|--------------|
|    | ... |    | 2.1 → 1st NN |
|    | ... |    | 2.4 → 2nd NN |
|    | ... |    | 3.1 → 3rd NN |
|  | ... |  | 4.5 → 4th NN |

| Class                                                                                 | # of votes |                                                                                                                                                                                                                                                                                                                                           |
|---------------------------------------------------------------------------------------|------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|  | 2          | ➔ Class  wins the vote!<br>Point  is therefore predicted to be of class  . |
|  | 1          |                                                                                                                                                                                                                                                                                                                                           |
|  | 1          |                                                                                                                                                                                                                                                                                                                                           |



# 1. KNN分类算法—举例




| 电影名称    | 打斗镜头 | 拥抱镜头 | 电影类型 |
|---------|------|------|------|
| 谍影重重    | 57   | 2    | 武打片  |
| 叶问3     | 65   | 2    | 武打片  |
| 我的特工爷爷  | 21   | 4    | 武打片  |
| 奔爱      | 4    | 46   | 情感片  |
| 夜孔雀     | 8    | 39   | 情感片  |
| 代理情人    | 2    | 38   | 情感片  |
| 这个杀手不太冷 | 49   | 6    | ?    |

## ■ 电影分类：

- 表格中6个样本（电影）分别给出其特征（打斗镜头、拥抱镜头）和标签（电影类型）信息，现在给定一个新的样本（这个杀手不太冷），我们想知道这部电影的类型。由于是2维数据，我们可以用平面直角坐标系表示。



# 1. KNN分类算法—举例



# 1. KNN分类算法—举例



$$D_{\text{谍影重重}} = \sqrt{(49 - 57)^2 + (6 - 2)^2} \approx 8.94$$

$$D_{\text{叶问3}} = \sqrt{(49 - 65)^2 + (6 - 2)^2} \approx 16.49$$

$$D_{\text{我的特工爷爷}} = \sqrt{(49 - 21)^2 + (6 - 4)^2} \approx 28.07$$

$$D_{\text{奔爱}} = \sqrt{(49 - 4)^2 + (6 - 46)^2} \approx 60.21$$

$$D_{\text{夜孔雀}} = \sqrt{(49 - 8)^2 + (6 - 39)^2} \approx 52.63$$

$$D_{\text{代理情人}} = \sqrt{(49 - 2)^2 + (6 - 38)^2} \approx 56.86$$

| 电影名称   | 与未知电影距离 |
|--------|---------|
| 谍影重重   | 8.94    |
| 叶问3    | 16.49   |
| 我的特工爷爷 | 28.07   |
| 夜孔雀    | 52.63   |
| 代理情人   | 56.86   |
| 奔爱     | 60.21   |

- 计算每部电影到《这个杀手不太冷》的距离并从小到大排序
- 当  $K=3$  和  $K=5$  时，前三个样本出现最多的电影类型都是武打片，因此《这个杀手不太冷》样本应该归为**武打片**



# 1. KNN分类算法 — 性能分析



优点:

实现简单;

处理大数据时表现良好;

形成的决策边界可以是任意形状的。

缺点:

维数灾难，且可能被无关属性影响距离;

K值对结果影响大

数据量大计算量大。



# 目 录

1

KNN分类

2

SVM分类

3

决策树分类




## 2. SVM分类算法 — 感知机



假设我们有一些黄色的梨和香蕉，  
现在已知他们的种类，通过仪器可  
以检测出他们的**宽度和高度**。

现在又有一些混合的黄色水果，  
机器该如何区分这两种水果呢？




## 2. SVM分类算法 — 感知机



水果的特征有两个，分别是宽度和高度，我们可以把宽度记为  $x_1$ ，高度记为  $x_2$ ，将它们绘制在一张图里。

图中红色的圆圈代表梨，蓝色的三角形代表香蕉。




## 2. SVM分类算法 — 感知机



观察可以发现，同样宽度下，香蕉的高度似乎更大。

为了将这两种水果分开，可以画一条线。该直线可以表示为  $f(x) = Ax_1 + Bx_2 + C = 0$ 。在直线上方与直线下方， $f(x)$  的值一正一负，通过  $f(x)$  的符号就可以把两种水果分开。



同样的数据可能存在多条这样的分类线，它们之中是否存在对分类最有好的直线呢？





## 2. SVM分类算法 — 感知机



引入感知机的概念，感知机是二分类的线性模型，其输入是实例的特征向量，输出的是实例的类别，分别是+1和-1，属于判别模型。

比如本例中，输入的特征向量是宽度和高度（ $X_1, X_2$ ），经过 $f(x) = Ax_1 + Bx_2 + C$ ，结果为正，输出+1，代表香蕉；结果为负，输出-1，代表梨。




## 2. SVM分类算法 — 感知机



- 在**二维**空间中，一条直线足以将两种类别完全分开。
- 在**三维**空间中，需要用一张平面将两种类别分开。
- **更高维**空间，我们无法画出图形，可以将其称为“超平面”，用超平面来区分两种类别。

假设训练数据集是线性可分的，感知机学习的目标是求得一个能够将训练数据集**正实例点和负实例点完全正确分开**的分离线或分离面。

如果是非线性可分的数据，则最后无法获得**分离线或分离面**。



## 2. SVM分类算法




### 支持向量机

(Support Vector Machine, SVM)

SVM 是一种在特征空间上**使分类间隔最大**的分类器，它对**两个类别**进行分类。

线性分类器是分类器中的一种，类似地，线性支持向量机也是支持向量机中的一种。若无特殊说明，我们这里说的支持向量机指的是线性支持向量机。



## 2. SVM分类算法




离分类直线**最近**的这些样本点对分类间隔大小非常“重要”，起着关键作用，这些样本点被称为**支持向量**。沿用感知机部分的问题描述与符号表示，如图：

几何间隔

$$d = \frac{|w_1x_1 + w_2x_2 + b|}{\sqrt{w_1^2 + w_2^2}}$$
$$= y \times \frac{w_1x_1 + w_2x_2 + b}{\sqrt{w_1^2 + w_2^2}}$$

分类间隔

分类间隔是支持向量几何间隔的两倍  $2d$ 。




**SVM的目标就是使得分类间隔 $2d$ 最大**，分类间隔越大，分类效果越好。



## 2. SVM分类算法 — SVM软间隔分类



- 软间隔 (soft margin) 分类
  - 通常情况下，训练集中会存在一些**异常点**，而这些异常点会导致训练集线性不可分，但除去这些异常点之后，剩下的样本就是线性可分的。
  - 线性不可分意味着有些样本点的函数间隔是不能满足大于等于 1 的约束条件。
- SVM优化问题（软间隔）：对分错的点，给予惩罚




## 2. SVM分类算法 — 核函数



在有些情况下，图像线性不可分，但是我们仍然有办法能够进行线性分类。  
我们可以通过叫做“**核函数**”的映射，将低维的数据映射到高维空间中。

原本在低维空间中线性不可分的样本，在**高维空间**中可能就线性可分了。



通过这种方式，我们可以解决一些线性不可分的问题。



$$\phi(x) = x$$

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

核函数




## 2. SVM分类算法 — 多分类




### ▪ 方案1: 1 vs all

- 训练类A与其他, 类B与其他, 类C与其他的二分类器



### ▪ 方案2: 1 vs 1

- 训练类A与B, 类B与C, 类C与A的二分类器



## 2.SVM分类算法 — 性能分析



### 优点:

引入了最大间隔，分类精确度高；

样本量较小时，也能准确的分类；

核函数可以解决非线性分类；

### 缺点:

样本量大时，计算速度慢；

多分类问题困难；



# 目 录

1

KNN分类

2

SVM分类

3


决策树分类



### 3.决策树分类 — 放学后活动选择



我爱学习，  
学习使我快乐



### 3.决策树分类 — 放学后活动选择



| 编号 | 距离考试情况 | 心情 | 朋友约游戏 | 放学后活动 |
|----|--------|----|-------|-------|
| 1  | 紧急     | 好  | 有约    | 学习    |
| 2  | 紧急     | 好  | 没约    | 学习    |
| 3  | 紧急     | 坏  | 有约    | 学习    |
| 4  | 紧急     | 坏  | 没约    | 学习    |
| 5  | 临近     | 好  | 有约    | 学习    |
| 6  | 临近     | 好  | 没约    | 学习    |
| 7  | 临近     | 坏  | 有约    | 打篮球   |
| 8  | 临近     | 坏  | 没约    | 打篮球   |
| 9  | 暂无     | 好  | 有约    | 打游戏   |
| 10 | 暂无     | 好  | 没约    | 打篮球   |
| 11 | 暂无     | 坏  | 有约    | 打游戏   |
| 12 | 暂无     | 坏  | 没约    | 打篮球   |




### 3.决策树分类 — 决策树介绍



**决策树学习算法**以树形结构建立模型，类似于流程图，模型本身包含一系列逻辑决策，带有根据某一特性做出决定的决策节点。决策树从根节点开始，由叶节点结束，节点引出的分枝表示可做出的选择，叶结点表示遵循决策组合的结果。

决策树是最广泛使用的机器学习技术之一，它几乎可以用于任何类型的数据建模，同时具有较好的性能。




### 3.决策树分类 — 决策树构建




**决策树构建**需要从根节点开始，判断实例的某个特征，根据这个特征的结果，将样本集划分为若干部分，然后以每一个部分再次作为根节点进行同样的操作。

选取特征的时候，**需要这个特征能够将样本的类别尽量分开**，也就是说，这个特征对样本分类很明显。

当一个节点里面的样本全部属于同一类别的时候，它就成为了叶节点，此时每一个样本都对应着决策树里的一条路径。



### 3.决策树分类 — 放学后活动选择



| 编号 | 距离考试情况 | 心情 | 朋友约游戏 | 放学后活动 |
|----|--------|----|-------|-------|
| 1  | 紧急     | 好  | 有约    | 学习    |
| 2  | 紧急     | 好  | 没约    | 学习    |
| 3  | 紧急     | 坏  | 有约    | 学习    |
| 4  | 紧急     | 坏  | 没约    | 学习    |
| 5  | 临近     | 好  | 有约    | 学习    |
| 6  | 临近     | 好  | 没约    | 学习    |
| 7  | 临近     | 坏  | 有约    | 打篮球   |
| 8  | 临近     | 坏  | 没约    | 打篮球   |
| 9  | 暂无     | 好  | 有约    | 打游戏   |
| 10 | 暂无     | 好  | 没约    | 打篮球   |
| 11 | 暂无     | 坏  | 有约    | 打游戏   |
| 12 | 暂无     | 坏  | 没约    | 打篮球   |

### 3.决策树分类 — 决策树特征选择



**决策树特征选择**有许多种方式。

- **ID3算法：**

ID3算法核心是在特征选择时计算每个特征产生的信息增益，选择**特征增益最大**的作为特征。

- **C4.5算法：**


C4.5算法在ID3上做了改进，使用**信息增益比**来判定特征。

- **CART算法：**


CART算法采用的是特征的取值来让树分枝，**一个节点只会分出两个树杈**，分别是属于特征 $A=a$ ，和不属于特征 $A=a$ 。



### 3.决策树分类 — 决策树“剪枝”



不纯度 = 0



不纯度 = 0.1

**The Simpler, The Better**

**“越简单的模型越好”**

### 3.决策树分类 — 数据类型



#### 连续型数据与离散型数据

- 离散型数据  
学历、职业、缴费方式、客户流失
- 连续型数据  
年龄、在网时长、费用变化率

| 年龄 | 学历  | 职业   | 缴费方式  | 在网时长/年 | 费用变化率/% | 客户流失 |
|----|-----|------|-------|--------|---------|------|
| 58 | 大学  | 公务员  | 托收    | 13     | 10.00   | NO   |
| 47 | 高中  | 工人   | 营业厅缴费 | 9      | 42.00   | NO   |
| 26 | 研究生 | 公务员  | 充值卡   | 2      | 63.00   | YES  |
| 28 | 大学  | 公务员  | 营业厅缴费 | 5      | 2.91    | NO   |
| 32 | 初中  | 工人   | 营业厅缴费 | 3      | 2.30    | NO   |
| 42 | 高中  | 无业人员 | 充值卡   | 2      | 100     | YES  |
| 68 | 初中  | 无业人员 | 营业厅缴费 | 9      | 2.30    | NO   |



### 3.决策树分类 — 数据类型



#### 连续型数据离散化

- **年龄**：年龄 $\leq 40$ ——青年； $40 < \text{年龄} \leq 50$ ——中年；年龄 $> 50$ ——老年
- **在网时长**：在网时长 $\leq 5$ ——H1；在网时长 $> 5$ ——H2
- **费用变化率**：F1、F2、F3

费用变化率 $\leq 30\%$ ——F1； $30 < \text{费用变化率} \leq 99\%$ ——F2；费用变化率 $= 100\%$ ——F3

| 年龄 | 学历  | 职业   | 缴费方式  | 在网时长/年 | 费用变化率/% | 客户流失 |
|----|-----|------|-------|--------|---------|------|
| 58 | 大学  | 公务员  | 托收    | 13     | 10.00   | NO   |
| 47 | 高中  | 工人   | 营业厅缴费 | 9      | 42.00   | NO   |
| 26 | 研究生 | 公务员  | 充值卡   | 2      | 63.00   | YES  |
| 28 | 大学  | 公务员  | 营业厅缴费 | 5      | 2.91    | NO   |
| 32 | 初中  | 工人   | 营业厅缴费 | 3      | 2.30    | NO   |
| 42 | 高中  | 无业人员 | 充值卡   | 2      | 100     | YES  |
| 68 | 初中  | 无业人员 | 营业厅缴费 | 9      | 2.30    | NO   |



### 3.决策树分类 — 数据类型



#### 连续型数据离散化

- 年龄：青年、中年、老年
- 在网时长：H1、H2
- 费用变化率：F1、F2、F3

| 年龄 | 学历  | 职业   | 缴费方式  | 在网时长/年 | 费用变化率/% | 客户流失 |
|----|-----|------|-------|--------|---------|------|
| 老年 | 大学  | 公务员  | 托收    | H2     | F1      | NO   |
| 中年 | 高中  | 工人   | 营业厅缴费 | H2     | F2      | NO   |
| 青年 | 研究生 | 公务员  | 充值卡   | H1     | F2      | YES  |
| 青年 | 大学  | 公务员  | 营业厅缴费 | H1     | F1      | NO   |
| 青年 | 初中  | 工人   | 营业厅缴费 | H1     | F1      | NO   |
| 中年 | 高中  | 无业人员 | 充值卡   | H1     | F3      | YES  |
| 老年 | 初中  | 无业人员 | 营业厅缴费 | H2     | F1      | NO   |



### 3.决策树 — 性能分析



#### 优点:

决策树易于理解和解释，可以可视化分析，容易提取出规则；  
可以同时处理标签型和数值型数据；  
比较适合处理有缺失属性的样本；  
数据测试，运行速度比较快。

#### 缺点:

容易发生过拟合；  
不同的判定准则会带来不同的属性选择倾向。





上海交通大学  
SHANGHAI JIAO TONG UNIVERSITY



人工智能研究院  
Artificial Intelligence Institute

谢谢!

饮水思源 爱国荣校